

深層学習を用いた OBI(On board imager)による直腸ガスの 判定に最適なモデルの検討

提出日 令和 8 年 12 月 14 日

主任指導教員 武村 哲浩 教授

指導教員 田中 利恵 准教授

令和 6 年度入学

金沢大学 医薬保健学総合研究科

保健学専攻 医療科学領域 量子医療技術学講座

学籍番号 2418031046

氏名 中村 公亮

目次

目次	1
要旨	2
1. 諸言	4
2. 方法	5
2.1 対象症例	5
2.2 実験方法	5
2.3 評価	8
3. 結果	9
4. 考察	11
5. 結論	14
謝辞	15
参考文献	16

要旨

【Purpose】

In IMRT (intensity-modulated radiotherapy) for prostate cancer, the presence of rectal gas can compromise treatment accuracy. Therefore, it is crucial to reliably determine the need for rectal gas evacuation before treatment. Typically, lateral images obtained using the OBI (On-Board Imager) attached to the treatment device are visually assessed, but this process is subjective and prone to inter-observer variability. This study aimed to build deep learning models for automatic detection of rectal gas from OBI images and to compare their performance.

【Methods】

A total of 300 OBI images obtained from 28 patients were analyzed, consisting of 75 images requiring rectal gas evacuation and 225 images not requiring intervention. Images were converted to 8-bit grayscale JPEG, normalized, and windowed, and labels were assigned based on CBCT (Cone-Beam Computed Tomography) acquired immediately after OBI. To enhance generalizability, three types of data augmentation were applied: translations ($\leq 10\%$), rotations ($\pm 5^\circ$), and variations in brightness ($\pm 30\%$) and contrast ($\pm 50\%$). Eight convolutional neural network (CNN) models AlexNet, ResNet, DenseNet, ResNeXt, GoogLeNet, VGG16, MobileNet, and WideResNet were fine-tuned via transfer learning and evaluated using Accuracy, Precision, Recall and F1-score.

【Results】

Among the tested models, WideResNet demonstrated the highest performance. WideResNet, in particular, achieved the best results across all metrics, with an Accuracy 0.956, Precision 0.964 Recall 0.956 F1-score of 0.958. In contrast, GoogLeNet yielded the lowest performance with an Accuracy 0.872 Precision 0.880 Recall 0.872 F1-score of 0.878.

【Discussion】

Residual network-based architectures demonstrated superior results, likely due to their enhanced feature extraction capabilities and stable training enabled by residual connections. WideResNet further improved representation power and generalization through increased network width and the use of dropout, contributing to its superior accuracy. ResNeXt introduced grouped convolutions (cardinality) in addition to residual connections, enabling richer feature representations and maintaining high performance. In contrast, GoogLeNet's heavy reliance on 1×1 convolutions for dimensionality reduction and its lack of skip connections may have contributed to its relatively inferior performance.

【Conclusion】

For automatic rectal gas detection from OBI images using deep learning, WideResNet and ResNeXt achieved the highest accuracy and appear to be promising candidates for clinical application. However, limitations remain, including the relatively small dataset, potential data leakage due to patient overlap, and the need for improved interpretability through visualization

techniques such as Grad-CAM. These issues warrant further investigation in future studies.

1. 諸言

前立腺がん治療では、リニアック(LINAC)を用いた強度変調放射線治療(IMRT)が主流であり、腫瘍に対して高精度な線量集中を行いつつ、周囲の正常組織への線量を低減することが求められる¹⁾.治療前にはリニアック付属のCBCT(Cone-Beam Computed Tomography)により患者体位を治療計画時の体位に位置合わせを行うが、直腸内にガスが貯留している場合、実際の PTV(Planning Target Volume)と照射中心の位置関係にずれが生じる.この際は、体位を変更して、患者にネラトンカテーテルを経肛門的に挿入してガス除去を行っ
たうえで位置の再調整とCBCTの再撮影が必要となる²⁾.CBCTの再撮影は被ばく量の増加を伴うため、必要最小限に抑えるべきである.そこで、当院では、治療前に取得する OBI (On Board Imager)画像により、骨盤側面画像を取得し、直腸部に低吸収域として描出されるガス像の有無を判断する運用がなされているが、現状では視覚的判断に依存しており、評価者間でのばらつきが課題となっている.

CNN は放射線治療分野において広く応用されており、臓器自動セグメンテーションや標的輪郭抽出、線量分布予測など多岐にわたる報告がある^{3,4,5)}.治療精度に影響を及ぼす直腸内ガスに着目した先行研究として Miura らは、Unet ベースの深層畳み込みニューラルネットワーク(DCNN)に 300 枚の 2D X 線画像を対象に、手動で作成した直腸ガスラベル教師データとして学習させ、前立腺がん治療前の X 線画像から直腸ガスを自動検出し、Dice 係数 0.85 という良好な精度を報告している⁶⁾.しかし同研究は、検出精度の評価にとどまり、直腸ガスの

有無だけで治療可否が決定されるわけではない点については十分に考慮されていない.実際には、ガスの位置や広がりが前立腺位置の変動や線量分布に与える影響が臨床上より重要である.本研究は、深層学習を用いて OBI 画像から直腸ガスの有無を判定する深層学習モデルを構築し、直腸ガス判定に最適なモデルを検討する.

2. 方法

2.1 対象症例

本研究では、28 人の前立腺がん IMRT 治療患者から OBI 側面画像を収集した. 膀胱充満状態については、全例で治療前に排尿後一定量の蓄尿を行うよう指導し、撮影時には膀胱容量の均一化を図った. 体位は全例で仰臥位を基本とし、うつ伏せでの撮影は行っていない. 固定具については、骨盤部の安定化のためにボディーシェルを併用した. 人工骨頭を有する症例は含まれていなかった. 画像は、ガス抜き要した 75 枚とガス抜きが不要だった 225 枚、合計 300 枚の画像を収集した. いずれも保存形式は DICOM 形式である. 各患者あたりの撮影は原則として治療前に 1 回行い、分割回数は 28 回の標準的な IMRT スケジュールに準拠している. このように患者背景・固定方法・体位・撮影条件を可能な限り統一することで、データの均一性を担保したうえで解析を行った.

2.2 実験方法

画像は ImageJ にて前立腺および直腸周囲が最も視認しやすくなるようウィンドウ幅・ウィンドウレベルを調整した後、8 ビット JPEG 形式に変換した. 変換後の JPEG 画像については、まず画素値を 255 で除算し $[0, 1]$ に

正規化した. さらに、データセット全体の画素値の平均値および標準偏差を算出し、これを用いて式 1 に定義される Z-score 変換により標準化を行った. なお、ここで x は元の画素値、 μ はデータセット全体の平均画素値、 σ は標準偏差、 x' は標準化後の画素値を表す⁷⁾.

$$x' = \frac{x - \mu}{\sigma} \cdot \cdot \cdot (1)$$

これにより入力範囲の統一と、撮影条件や画像ごとの輝度分布のばらつきに起因するダイナミックレンジの差の補正を同時に実現し、学習の安定性を確保した. 本研究におけるラベリングは、治療履歴に基づいて決定した. 具体的には、OBI 撮影後に取得した CBCT を確認し、直腸ガスが治療に影響しないと判断され、そのまま治療へ移行している症例は「ガス抜き不要」とラベリングした. 一方で、直腸ガスが治療に影響すると判断されガス抜き処置が行われた症例については、処置後に再度 CBCT が撮影されるため、当該 OBI を「ガス抜き必要」としてラベリングした. すなわち、1 回の治療において CBCT が 2 回撮影されている患者は、ガス抜きが必要と判定された症例と定義した. 放射線治療実施時の決定は、放射線治療に従事する診療放射線技師 2 名（うち経験年数 10 年以上が 1 名、3 年未満が 1 名）が独立して実施し、判断に相違がある場合は第三者（経験 15 年以上の放射線治療専門技師）が合議により最終判定を行った. この体制により、ラベリング基準の一貫性と再現性を担保した.

本研究では、モデルの汎化性能を高めるために 3 種類のデータ拡張を行った. 第 1 に、画像を幅・高さの 10% 以内でランダムにシフトさせる処理を行い、患者の撮影位置変動に対するロバスト性を強化した. 第 2 に、画像を -5 度から +5 度の範囲でランダムに回転させ、患者の姿勢やポジショニング変動に対応可能とし

た.第 3 に、明るさを $\pm 30\%$ 、コントラストを $\pm 50\%$ の範囲でランダムに調整し、モニターの輝度や患者体格・撮影条件によるコントラストの違いに対する汎用性を強化した.これらの操作は、近年の医用画像分野におけるデータ拡張に広く利用される手法に基づいており、日常診療における撮影体位や照射条件のばらつきを模擬する範囲で設定した⁸⁾.

使用したモデルは、既存の代表的な深層学習モデルである AlexNet⁹⁾, ResNet¹⁰⁾, DenseNet¹¹⁾, ResNeXt¹²⁾, GoogLeNet¹³⁾, VGG16¹⁴⁾, MobileNet¹⁵⁾, WideResNet¹⁶⁾の 8 種類の学習済みネットワークである.これらはいずれも ImageNet で事前学習された公開モデルであり、CNN の基盤的アーキテクチャから残差接続、密結合、軽量化設計、幅方向の拡張まで、異なる設計思想を代表するものである. 入力画像を 224×224 にリサイズし 3 チャンネルに複写、最適化関数は、確率的勾配降下法 (SGD: Stochastic Gradient Descent) を使用し、予備実験において学習の安定性と収束性を確信した上で、学習率は 1×10^{-3} に設定した. バッチサイズは 32、学習は 300 epoch で実施した.各モデルを用いて直腸ガスの有無を分類し、validation データにより性能を評価した.さらに、クラス分布の偏りを考慮するため Stratified K-Fold クロスバリデーションを採用した.これはデータセットを K 個に分割する際、各フォールド内の「ガス抜き必要:不要=75:225」という比率を再現し、クラス不均衡下でも安定かつ公平な、訓練と検証を繰り返した¹⁴⁾.各モデルの最終出力確率を、モデルが出力する確率分布における標準的な判定基準であり、クラス間の事前確率を仮に等しいとみなし、0.5 で二値化し、0.5 以上をガス抜き必要、0.5 未満をガス抜き不要と判定した.使用機器としては、NVIDIA A100 GPU を搭載した計算環境を用い、学習フレームワークとして PyTorch ver. 2.3.0 を、統計解析には scikit-learn (ver. 1.3.2) を使用した.

2.3 評価

本研究における評価は、既存の深層学習を用いた医用画像領域で一般的に用いられている指標に基づいて行った⁸⁾。評価指標として、TP(True Positive), FP(False Positive), TN(True Negative), FN(False Negative)を算出し、それらを基に Accuracy, Precision, Recall, F1-score を計算した。ここで、TP は「ガス抜き必要」と正しく判定された症例数、FP は「不要」を誤って「必要」と判定した症例数、TN は「不要」と正しく判定された症例数、FN は「必要」を見逃して「不要」と判定した症例数と定義した。各指標は式 2-5 に定義される。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \cdot \cdot \cdot (2)$$

$$Precision = \frac{TP}{TP + FP} \cdot \cdot \cdot (3)$$

$$Recall = \frac{TP}{TP + FN} \cdot \cdot \cdot (4)$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \cdot \cdot \cdot (5)$$

Accuracy は全体的な正確性を示し、Precision は誤検出の抑制、Recall は見逃し防止に重点を置いた指標である。F1-score は Precision と Recall の調和平均であり、クラス不均衡下におけるモデル性能評価に有用である。

本研究では、臨床現場における安全性の観点から「見逃し(FN)」と「誤検出

(FP)」の両方を最小化することが重要であると考えた。そのため、Precision (誤検出の抑制) と Recall (見逃し防止) のバランスを総合的に評価できる F1-score を主指標とし、Accuracy は補助的に参照し、最適なモデルを検討した。

3. 結果

本研究では 8 種類の CNN モデルを用いて、直腸ガスの有無を判定における性能を比較した。評価指標には Accuracy、Precision、Recall、F1-score を用いた。結果を Table1 に示す。

Table 1 各モデルの評価指標

	Accuracy	Precision	Recall	F1-score
AlexNet	0.904	0.902	0.904	0.904
ResNet	0.950	0.950	0.950	0.950
DenseNet	0.948	0.948	0.948	0.950
ResNeXt	0.956	0.956	0.956	0.954
GoogLeNet	0.872	0.88	0.872	0.878
VGG16	0.946	0.952	0.946	0.948
MobileNet	0.952	0.954	0.952	0.952
WideResNet	0.956	0.964	0.956	0.958

F1-score を主要評価指標とした場合、最も優れたモデルは WideResNet 0.958 であり、次いで ResNeXt 0.954、MobileNet 0.952 が高い値を示し

た.ResNet および DenseNet はいずれも 0.950 と同等の水準であり、VGG16 0.948 がそれに続いた.AlexNet は 0.904 と中程度の成績であった一方、GoogLeNet は 0.878 と全モデル中最も低い値を示した.

Accuracy においても同様の傾向がみられ, WideResNet と ResNeXt がともに 0.956 と最も高く, MobileNet が 0.952, ResNet が 0.950, DenseNet が 0.948, VGG16 が 0.946 と高精度を示した.これに対して, AlexNet は 0.904, GoogLeNet は 0.872 と相対的に低値にとどまった.

Precision の結果もおおむね一致しており, WideResNet が 0.964 で最高値を示し, ResNeXt が0.956, MobileNet が 0.954 と続いた.ResNet と DenseNet はいずれも 0.950, VGG16 が 0.952, AlexNet が 0.902, GoogLeNet が 0.880 であった.

Recall に関しても WideResNet と ResNeXt が 0.956 と最も高く, MobileNet が 0.952, ResNet が 0.950, DenseNet が 0.948, VGG16 が 0.946 と良好な値を示した.一方, AlexNet は 0.904, GoogLeNet は 0.872 と低かった.

4. 考察

本研究では、複数の畳み込みニューラルネットワーク(CNN)モデルを用いて直腸ガスの有無判定を行い、その性能を比較した。結果として、本研究ではDenseNet、WideResNet、MobileNet、ResNeXt が高精度を示した。一方、GoogLeNet は性能が劣る傾向を示した。WideResNet は ResNet を基盤として「深さ」ではなく「幅」を拡張することで表現力を強化している。標準的なResNet が深層化により表現力を高める一方で、勾配消失や計算コスト増加といった問題を抱えるのに対し、WideResNet は畳み込みチャンネル数を増やすことで表現力を強化している。また、Residual Block 内に Dropout を導入することで、並列的な特徴抽出を行いつつ過学習を抑制している。この設計により、F1-score 0.958, Precision 0.964, Recall 0.956, Accuracy 0.956 と全ての指標で最高水準の値を示し、OBI 画像のように組織構造やガス像の変動が多様なデータに対しても頑健な識別が可能となり、本研究で全モデル中最高の精度を示した要因と考えられる¹⁶⁾。

ResNeXt は ResNet の残差構造に加え、グループ化された並列畳み込み(cardinality)を導入することで表現力を拡張したモデルである¹²⁾。本研究でもF1-score 0.954 と次点であり、Accuracy, Precision, Recall においてもWideResNet と同等の水準を示した。しかし、構造上、並列畳み込みを多く導入するため計算効率が環境に依存し、実運用上は WideResNet に劣ると考えられる。

MobileNet は Depthwise Separable Convolution に基づく軽量設計により、パラメータ数を削減しつつ高い精度を達成する¹⁵⁾。これにより軽量でありながら表現力を保つことができる。F1-score 0.952 と高い性能を示したが、Precision 0.954 に対して Recall は 0.952 にとどまり、偽陰性の低減が求められる本研

究においては最適モデルとはならなかった。ただし OBI 画像のリアルタイム解析や臨床現場でのワークフローを想定すると、MobileNet の軽量性は実装上の利点となる可能性が高い。さらに近年では、物体追跡アルゴリズムである LightFC においても、入力画像から特徴を抽出するための基盤モデルとして利用されており、軽量性と高精度を両立する点から臨床応用におけるリアルタイム判定や装置組み込みへの展開が期待される¹⁸⁾

DenseNet は全層を密に結合する DenseBlock 構造を有しており、特徴の再利用と勾配消失の回避を可能にする¹¹⁾。本研究では、F1-score 0.950 と高精度を示したが、Accuracy 0.948 と、WideResNet には及ばなかった。DenseNet の特徴再利用構造は小規模データに有効とされるが、本研究の結果では性能の限界が確認され、最適モデルからは外れた。

一方で、GoogLeNet は Inception 構造により計算効率を重視しているが、 1×1 畳み込みによる過度の次元削減が局所的な情報喪失を招く可能性がある。また、ResNet 系や DenseNet 系に導入されているようなスキップ接続を欠いており、深層化した際の勾配伝播が不十分となる問題がある。結果として、本研究では複雑な局所構造の識別が困難となり、全モデル中で最も低い性能にとどまったと考えられる¹³⁾。近年では Inception-v4 といった改良版により性能改善が報告されており、構造的制約が克服されれば本研究への適用可能性は再評価される余地がある¹⁹⁾。

本研究は 28 例・300 枚の画像を対象としており、限られた症例数の範囲内で解析を行った。症例はすべて同一施設で取得されたものであり、体位、固定方法などの条件は一定の統一性を有していた一方で、患者背景の多様性や撮影条件の幅広さについては十分とはいえない。したがって、本研究の結果が他施設やより多様な患者群に一般化できるかどうかは、さらなる検証を要する。本研

究では、各モデルの最終層が出力する確率値(0～1)を二値に変換する際、0.5をしきい値として「直腸ガスあり(=CBCT 必要)」と「なし(=不要)」を判定した.しかし、ROC 曲線に基づく最適なしきい値の探索や、Platt scaling・temperature scaling などによる確率較正は実施していない.そのため、今後は臨床における誤検出と見逃しのコスト差を考慮したしきい値の最適化や、確率較正の導入を検討する余地がある.

5. 結論

本研究では、前立腺がんに対する強度変調放射線治療(IMRT)において直腸ガスの有無を自動判定する深層学習モデルを構築し、8 種類の代表的 CNN を比較検討した.DenseNet、WideResNet、ResNeXt、MobileNet はいずれも Accuracy 約 0.95、F1-score 0.95 前後 と高精度を示した.特に WideResNet は Accuracy 0.956、Precision 0.964、Recall 0.956、F1-score 0.958 と全指標で最良の成績を示した.一方で GoogLeNet は Accuracy 0.872、F1-score 0.878 と最も低い精度にとどまった.

以上の結果から、WideResNe は直腸ガス判定に有望な候補モデルであり、臨床応用の可能性を有すると考えられる.今後はデータセットの拡充や交差検証による汎化性能の評価、さらに Grad-CAM 等による予測根拠の可視化を通じて、臨床導入に向けた信頼性と解釈性の向上が求められる²⁰⁾.

謝辞

本研究を行うにあたり，日頃より熱心なご指導を賜りました金沢大学医薬保健研究域保健学系 武村哲浩教授，田中利恵准教授に心より御礼申し上げます．また，日頃より有益なご討論ご助言をいただきました本研究室各位に感謝申し上げます．なお，本研究は金沢医科大学倫理委員会の承認（承認番号：H373）を得て実施した．

参考文献

- 1) Fischer Valuck BW, Rao YJ, Michalski JM.
Intensity-modulated radiotherapy for prostate cancer. *Transl Androl Urol*. 2018; 7(3):297–307. doi:10.21037/tau.2017.12.16
- 2) Sasaki M, Ikushima H, Tsuzuki A, Sugimoto W.
The effect of rectal gas on dose distribution during prostate cancer using volumetric modulated arc therapy (VMAT). *Rep Pract Oncol Radiother*. doi:10.1016/j.rpor.2020.09.013 (PMC7575650)
- 3) Men K, Zhang T, Chen X, Chen B, Tang Y, Wang S, et al. Fully automatic and robust segmentation of the clinical target volume for radiotherapy of breast cancer using big data and deep learning. *Phys Med*. 2018; 50:13–19. doi:10.1016/j.ejmp.2018.05.006
- 4) Cardenas CE, McCarroll RE, Court LE, Elgohari BA, Elhalawani H, Fuller CD, et al. Deep learning algorithm for auto-delineation of high-risk oropharyngeal clinical target volumes with built-in Dice similarity coefficient parameter optimization function. *Int J Radiat Oncol Biol Phys*. 2018; 101(2):468–478. doi:10.1016/j.ijrobp.2018.01.114
- 5) Nguyen D, Jia X, Sher D, Lin MH, Iqbal Z, Liu H, et al. 3D radiotherapy dose prediction on head and neck cancer patients with a hierarchically densely connected U-net deep learning architecture. *Phys Med Biol*. 2019;

64(6):065020. doi:10.1088/1361-6560/ab039b

- 6) Miura H, Ozawa S, Doi Y, Nakao M, Ohnishi K, Kenjo M, et al.
Automatic gas detection in prostate cancer patients during image-guided radiation therapy using a deep convolutional neural network. *Phys Med.* doi:10.1016/j.ejmp.2019.06.009
- 7) Al-Faiz MZ, Ibrahim AA, Hadi SM. The effect of Z-score standardization on binary input due the speed of learning in back-propagation neural network. *J Al-Nahrain Univ (Sci)*. 2018; 21(4):101–108.
- 8) Islam T, Hafiz MS, Jim JR, Kabir MM, Mridha MF.
A systematic review of deep learning data augmentation in medical imaging: Recent advances and future research directions. *Healthcare Analytics*. doi:10.1016/j.health.2024.100340
- 9) Krizhevsky A, Sutskever I, Hinton GE. ImageNet classification with deep convolutional neural networks (AlexNet). *Commun ACM*. 2017; 60(6):84–90. doi:10.1145/3065386
- 10) Szegedy C, Ioffe S, Vanhoucke V, Alemi A. Inception-v4, Inception-ResNet and the impact of residual connections on learning. arXiv preprint arXiv:1602.07261. 2016. doi:10.48550/arXiv.1602.07261

- 11) Zhu H, Wang W, Ulidowski I, Zhou Q, Wang S, Chen H, et al. MEEDNets Medical image classification via ensemble bio-inspired evolutionary DenseNets. *Knowl Based Syst* . doi:10.1016/j.knosys.2023.111035
- 12) Xie S, Girshick R, Dollár P, Tu Z, He K. Aggregated residual transformations for deep neural networks (ResNeXt). In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2017;1492–1500. doi:10.1109/CVPR.2017.634.
- 13) Szegedy C, Liu W, Jia Y, Sermanet P, Reed S, Anguelov D, et al. Going deeper with convolutions (Inception v1). In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2015;1–9. doi:10.1109/CVPR.2015.7298594.
- 14) Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition(VGG16). *arXiv preprint arXiv:1409.1556*. 2015. doi:10.48550/arXiv.1409.1556
- 15) Howard AG, Zhu M, Chen B, Kalenichenko D, Wang W, Weyand T, et al. MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv*. 2017; arXiv:1704.04861.
- 16) Zagoruyko S, Komodakis N. Wide residual networks. In: *Proceedings of the British Machine Vision Conference*. 2016;87.1–87.12. doi:10.5244/C.30.87.

- 17) Pedregosa F, Varoquaux G, Gramfort A, Michel V, Thirion B, Grisel O, et al. Scikit-learn: Machine learning in Python. *J Mach Learn Res.* 2011; 12:2825–2830.
- 18) Li Y, Wang B, Wu X, Liu Z, Li Y. Lightweight Full-Convolutional Siamese Tracker. *Knowl Based Syst.* 2024; 286:111439. doi:10.1016/j.knosys.2024.111439
- 19) Szegedy C, Ioffe S, Vanhoucke V, Alemi AA. Inception-v4, Inception-ResNet and the impact of residual connections on learning. *Proc AAAI Conf Artif Intell (AAAI-17).* 2017; 31:4278–4284.
- 20) Huff DT, Weisman AJ, Jeraj R. Interpretation and visualization techniques for deep learning models in medical imaging. *Med Phys.* 2021;48(1):e30–e46. doi:10.1002